

Statistiques descriptives

Julien Godet



1

Avant propos

La méthode scientifique est une méthode de conjectures audacieuses et de tentatives ingénieuses et sévères pour les réfuter.
(Karl Popper, La Connaissance objective, 1972)

Conjectures et réfutations

Le principe est donc de malmener des hypothèses/connaissances à l'aide de données

- approche fréquentiste
 - on part d'une hypothèse (souvent hypothèse d'égalité)
 - soit on rejette cette hypothèse
 - soit on ne peut pas la rejeter et on la conserve (pour le moment...)
- approche bayésienne
 - on dispose d'un *a priori* sur un phénomène
 - la question est de savoir si (et comment) les données changent cet *a priori*

Une bonne partie du travail consiste donc à rendre intelligible les données
(en les organisant, en les décrivant,...)

C'est l'objet des statistiques descriptives

2

Qu'est ce qu'on va apprendre à faire ?

- Découvrir les principaux éléments techniques utilisés pour décrire des données
- Connaître le vocabulaire et les principaux paramètres
- Savoir choisir les 'bons' paramètres ou les bonnes représentations graphiques pour décrire une/des caractéristique(s) d'intérêt dans les données
- Savoir interpréter les résultats d'une analyse descriptive

3

1. Des données?

Les données ressemblent souvent à ça (dans le meilleur des cas)



<https://www.shorturl.at/kuPTY>

	patientID	age	genre	taille	imc	fumeur	cancer	tabacPA	dc	dateEntree
1	1	52.38705	H	1.71	23.9	oui	oui	3.7	1	2017-01-~
2	2	66.15234	F	1.64	35.3	non	non	0.0	1	2017-05-~
3	3	74.75090	F	1.73	25.7	non	non	0.0	0	2017-02-~
4	4	NA	F	1.65	23.9	non	non	0.0	1	2017-08-~
5	5	46.65646	F	1.66	20.5	non	non	0.0	1	2017-03-~
6	6	56.07554	H	1.87	29.9	non	non	0.0	0	2017-02-~
7	7	60.94117	H	1.78	30.3	oui	non	4.8	0	2017-05-~
8	8	62.94065	F	1.59	29.2	non	non	0.0	1	2017-06-~
9	9	80.32070	F	1.62	26.5	oui	oui	13.8	1	2017-05-~
10	10	45.02499	H	1.72	22.7	non	non	0.0	0	2017-07-~

Showing 1 to 11 of 200 entries, 14 total columns

Aperçu du fichier : data1.csv

Regardons plus en détail ces données...

Comment rendre intelligible ces données ?

Comment organiser ces données ?

Comment résumer l'information ?

4

2. Un peu de terminologie

patientID	age	genre	taille	imc	fumeur	cancer	tabacPA	dc	dateEntree
1	52.38705	H	1.71	23.9	oui	oui	3.7	1	2017-01-2
2	66.15234	F	1.64	35.3	non	non	0.0	1	2017-05-2
3	74.75090	F	1.73	25.7	non	non	0.0	0	2017-02-2
4	NA	F	1.65	23.9	non	non	0.0	1	2017-08-0
5	46.65646	F	1.66	20.5	non	non	0.0	1	2017-03-2

Dans ce tableau :

- Chaque case du tableau correspond à une **donnée**
- Chaque colonne correspond à une **variable**
Une variable est un caractère (mesuré) d'un phénomène.
- Chaque ligne correspond à l'ensemble des données d'un sujet
- Il arrive qu'une case soit vide : on parle de **données manquantes**
Notation *NA* dans R, *nan* dans Python

5

2. Un peu de terminologie (suite)

patientID	age	genre	taille	imc	fumeur	cancer	tabacPA	dc	dateEntree
1	52.38705	H	1.71	23.9	oui	oui	3.7	1	2017-01-2
2	66.15234	F	1.64	35.3	non	non	0.0	1	2017-05-2

Il existe plusieurs types de variables:

• Variable quantitative

Quand cela a un sens de dire qu'un résultat est plus grand qu'un autre, qu'il est possible de faire la somme de 2 résultats, ...

- Une variable est dite **quantitative discrète** (ou discontinue) si elle ne peut prendre que certaines valeurs



ex: le nombre de caries chez un enfant (0,1, 2, 3, ... ,et pas 3.2 ou 0.78)

Souvent stockées en nombres entiers (integer) en informatique

- Sinon, on dit qu'elles sont **quantitatives continues**



ex: le taille d'une personne, son indice de masse corporelle (imc),...

Souvent stockées en nombres décimaux (double ou float) en informatique

6

2 Un peu de terminologie (... et fin)

•Variable qualitative

Si une variable n'est pas quantitative, elle est **qualitative** (ou catégorielle).

Une variable qualitative peut-être **ordinaire**...

Les modalités de la variables peuvent être ordonnées



ex: protéinurie sur une bandelette (0, +, ++, +++)

ex: mention au bac: excellent, très bien, bien, assez-bien, passable

... ou pas (variable **nominale**)



ex: groupe sanguin (A,B,O,AB)

Une variable est dite **binaire** si elle n'a que 2 modalités , ...



ex: oui/non, 1/0, présent/absent, féminin/masculin



Ce n'est pas parce que des variables sont des nombres qu'elles sont quantitatives!!

ex: la première colonne des codes patients (patientID)

Une variable codée 1/0 est souvent appelée **variable indicatrice** (*dummy variable*)

7

3. Un outil pratique : le cahier de variables

patientID	age	genre	taille	imc	fumeur	cancer	tabacPA	dc	dateEntree
1	52.38705	H	1.71	23.9	oui	oui	3.7	1	2017-01-2
2	66.15234	F	1.64	35.3	non	non	0.0	1	2017-05-2
3	74.75090	F	1.73	25.7	non	non	0.0	0	2017-02-2
4	NA	F	1.65	23.9	non	non	0.0	1	2017-08-2
5	46.65646	F	1.66	20.5	non	non	0.0	1	2017-03-2

Variable	Nom	Classe	Codage	Modalités	Commentaire
patientid	Numéro d'identification des Sujets	Indicatrice	factor	1:200	
age	Age	continue	double		en années, à l'entrée dans l'étude
genre	Sexe des patients	Nominale	factor	F/H	H: Homme; F: Femme
taille	Taille en mètre	continue	double		en m, à l'entrée dans l'étude
imc	Indice de masse corporelle	continue	double		Poids en kg / (taille en m) ² , à l'entrée dans l'étude
fumeur	patient fumeur	indicatrice	factor	oui/non	à l'entrée dans l'étude
cancer	cancer du poumon	indicatrice	factor	oui/non	
tabacPA	consommation de tabac en paquet année	continue	double		https://fr.wikipedia.org/wiki/Paquet-année
dc	vivant/décédé	indicatrice	integer	1/0	1:oui, 0:non
dateEntree	date d'entrée dans l'étude	date	character		
dateFinSui	date de fin de suivi	date	character		Si décédé: date de décès, sinon, date de dernière nouvelles (ou DP)
deltaT.jours	intervalle de temps entre dateEntree et dateFinSui	discrete	integer		en jours
deltaT.moi	intervalle de temps entre dateEntree et dateFinSui	discrete	integer		en mois
scorePred	score de mortalité	continue	double		score prédictif de mortalité (score élevé associé à risque accru de décès)

Le cahier de variables regroupe des informations détaillées sur les variables du jeu de données

8

4. Pourquoi décrire les données?

Avoir une vue d'ensemble des données

Observer facilement:

- Tendance centrale
- Dispersion
- Valeurs aberrantes, valeurs manquantes
- .../...


Comment décrire des données?

Paramètres numériques

Représentations graphiques

9

Décrire c'est représenter graphiquement...



Décrire c'est aussi tabuler des données...

Dans les présentations des résultats d'études cliniques, on trouve très souvent la description des caractéristiques des patients inclus dans l'étude.

Dans cet exemple sont décrits:

- des effectifs
- des pourcentages
- des moyennes
- des médianes
- des étendues
- .../...

(le tableau complet fait une page)

The NEW ENGLAND JOURNAL of MEDICINE		
ESTABLISHED IN 1812	JUNE 23, 2011	VOL. 364 NO. 25
Exemestane for Breast-Cancer Prevention in Postmenopausal Women		
Paul E. Goss, M.D., Ph.D., James H. Francis, M.D., Jose E. Barlow, M.D., Ph.D., Angela M. Cheung, M.D., Ph.D., Robert T. Chlebowski, M.D., Ph.D., Jean Wactawski-Wende, Ph.D., Anne McTearns, M.D., John Robbins, M.D., Karen C. Johnson, M.D., M.P.H., Lisa M. Martin, M.D., Eric Winer, M.D., Gloria E. Soto, M.D., Judy E. Garber, M.D., Carol J. Fabian, M.D., Pascal Pujol, M.D., Elizabeth Maunula, Ph.D., Patricia Farmer, M.D., Karen A. Gelmon, M.D., Dongsheng Tu, Ph.D., and Harriet Richardson, Ph.D., for the NCIC CTG MAP.3 Study Investigators*		
Table 1. Baseline Characteristics of Patients Randomly Assigned to Exemestane or Placebo.^{†‡}		
Characteristic	Exemestane (N=2285)	Placebo (N=2275)
White race — no. of patients (%) [†]	2138 (93.6)	2123 (93.3)
Age		
Median — yr	62.5	62.4
Range — yr	38.5–88.2	37.1–89.9
≥60 yr — no. of patients (%)	1545 (67.6)	1572 (69.1)
Body-mass index [‡]		
Median	27.9	28.1
Range	15.9–54.3	16.3–65.4
Breast cancer risk factors — no. of patients (%)		
Gail score indicating 5-year risk >1.66% [§]	929 (40.7)	905 (39.8)
Age ≥60 yr	1114 (48.8)	1126 (49.5)
Prior ADH, ALH, or LCIS on breast biopsy	185 (8.1)	188 (8.3)
Prior DCIS treated with mastectomy	56 (2.5)	56 (2.5)
.../...		
In L1–L4 posteroanterior spine		
No. of patients assessed	1990	2010
Mean value — g/cm ²	1.06±0.39	1.06±0.39

* Plus-minus values are means ±SD. Women may have received more than one prior therapy and may have had more than one medical problem. ADH denotes atypical ductal hyperplasia, ALH atypical lobular hyperplasia, DCIS ductal carcinoma in situ, and LCIS lobular carcinoma in situ.

† Race was self-reported.

‡ The body-mass index is the weight in kilograms divided by the square of the height in meters.

§ The Gail score calculates breast cancer risk based on known clinical risk factors (see www.cancer.gov/bcrisktool and the Supplementary Appendix at NEJM.org).

4.1 La description des variable dépend de leur nature

○ Variables qualitatives

Simplement résumées par les effectifs et fréquences de leurs modalités

- L'effectif d'une modalité correspond au nombre de fois où la modalité apparaît.
- L'effectif total de la variable correspond à la somme de tous les effectifs des modalités.
- La fréquence d'une modalité correspond à son effectif sur le total

Soit une série de N mesures $x_1, x_2, \dots, x_n$
dont N' données non manquantes
et avec par ex. $x_i \in \{0, 1\}$

	Variable x	Fréquence	Fréquence
Modalité 0	n_1	n_1 / N	n_1 / N'
Modalité 1	n_2	n_2 / N	n_2 / N'
Manquants	n_3	n_3 / N	

```
Code Python
dataL1['genre'].value_counts()

## H    120
## F     80
## Name: genre, dtype: int64

dataL1['genre'].value_counts(normalize=True)

## H    0.6
## F    0.4
## Name: genre, dtype: float64
```

```
Code R
table(dataL1$genre)

##
## F H
## 80 120

prop.table(table(dataL1$genre))

##
## F H
## 0.4 0.6
```

4.2 La description des variable quantitatives

1. Paramètres de position

Mesurent l'ordre de grandeur d'une variable (moyenne, médiane, mode,...)


2. Paramètres de dispersion

Estiment le niveau de variabilité (variance, intervalle inter-quartile, étendue,...)


o Mode

Valeur la plus fréquemment observée

i On décrit souvent les distributions comme étant uni/bi/plurimodales



Distribution unimodale (monomodale)



Distribution bimodale

13

Paramètres de position

o Moyenne arithmétique

Soit une série de N mesures $x_1, x_2, \dots, x_n$

d'une variable quantitative, la moyenne arithmétique est définie par:

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{N} = \frac{1}{N} \sum_{i=1}^N x_i$$

patientID	age	genre	taille	imc	fumeur	cancer	tabacPA	dc	dateEntree
1	52.38705	H	1.71	23.9	oui	oui	3.7	1	2017-01-
2	66.15234	F	1.64	35.3	non	non	0.0	1	2017-05-
3	74.75090	F	1.73	25.7	non	non	0.0	0	2017-02-
4	NA	F	1.65	23.9	non	non	0.0	1	2017-08-
5	46.65646	F	1.66	20.5	non	non	0.0	1	2017-03-

Code Python

```
import statistics as stat
stat.mean(dataL1['tabacPA'])
## nan
stat.mean(dataL1['tabacPA'].dropna())
## 2.3378947368421055
```

Code R

```
#
mean(dataL1$tabacPA)
## [1] NA
mean(dataL1$tabacPA, na.rm=TRUE)
## [1] 2.337895
```

14

Paramètres de position

○ Médiane



valeur qui partage une série ordonnée
en 2 groupes d'effectif identique


- Série de valeurs impaires ($n=2p+1$ éléments)

médiane = $(p + 1)^{\text{ème}}$ valeur


- Série de valeurs paires ($n=2p$ éléments)

médiane = demi-somme de la $(p)^{\text{ème}}$ et de la $(p + 1)^{\text{ème}}$ valeur

Ex: $n=7$; {10,7,2,5,6,9,8}



Ex: $n=4$; {1,3,9,6}



Code Python

```
import statistics as stat
stat.mean(data1['tabacPA'])

## nan
stat.mean(data1['tabacPA'].dropna())

## 2.3378947368421055
stat.median(data1['tabacPA'])

## nan
stat.median(data1['tabacPA'].dropna())

## 0.0
```

Code R

```
#
mean(data1$tabacPA)

## [1] NA
mean(data1$tabacPA, na.rm=TRUE)

## [1] 2.337895
median(data1$tabacPA)

## [1] NA
median(data1$tabacPA, na.rm=TRUE)

## [1] 0
```

15


Des différences entre médiane et moyenne ?

Code R

```
set.seed(12345)
val <- rnorm(n=500, mean=2, sd=1)
mean(val)

## [1] 2.082461
median(val)

## [1] 2.102492
hist(val, main="", xlab="")
```



Code R

```
#
val[1] <- 1500
mean(val)

## [1] 5.07729
median(val)

## [1] 2.102492
#
```

Dans la série initiale de 500 valeurs, la médiane et la moyenne sont quasi confondues (très proches)

Si on remplace une seule valeur par une valeur très grande, la moyenne est changée, la médiane presque pas

La moyenne peut être largement affectée par des valeurs très grandes (ou très petites)


La médiane est plus **robuste** que la moyenne : sa valeur est moins affectée par les valeurs extrêmes.

16

Des différences entre médiane et moyenne ?

```
Code R
m.bar <- mean(dataL1$deltaT.jours)
m.tilde <- median(dataL1$deltaT.jours)


hist(dataL1$deltaT.jours, main = "",
      xlab="Jours")
abline(v=m.bar, col="blue")
abline(v=m.tilde)
legend("topright", col = c("blue",1),
      lwd=2,c("médiane","moyenne" ))
```



Si la distribution d'une variable est asymétrique, il est probable que la moyenne et médiane ne soient pas égales

```
Code R
m.bar <- mean(dataL1$scorePred,na.rm=T)
m.tilde <- median(dataL1$scorePred,na.rm=T)

hist(dataL1$scorePred, main = "",
      xlab="Score")
abline(v=m.bar, col="blue")
abline(v=m.tilde)
legend("topright", col = c("blue",1),
      lwd=2,c("médiane","moyenne" ))
```



Si la distribution des données est symétrique, la moyenne et la médiane peuvent être confondues

La médiane est plus **robuste** que la moyenne : si la distribution de la variable est asymétrique, c'est sans doute le paramètre de position à privilégier.

17

Quartiles et box-plots

○ Quartiles




valeurs qui partagent une série ordonnée en 4 groupes d'effectifs identiques

- On note Q1 et Q3 le premier et troisième quartile respectivement
- Q2 = médiane

Utilisé dans les box-plots (ou boîtes à moustaches)

Ex: on représente les pressions artérielles diastoliques (PAD) et systoliques (PAS) mesurées chez 50 patients



- La boîte centrale est définie par Q1 et Q3. Elle contient 50% des valeurs
- La position de la médiane par rapport à la boîte renseigne sur la symétrie de la distribution
- La manière de définir les moustaches varie d'une représentation à l'autre.
Ici c'est la distance médiane – min (ou max) dans la limite de 1.5 fois la distance Q1-Q3
- Les points sont les valeurs individuelles qui ne sont pas comprises dans l'intervalle défini par les moustaches - valeurs extrêmes ou aberrantes (outliers)

18

Généralisation aux quantiles

○ Quartiles



valeurs qui partagent une série ordonnée en 4 groupes d'effectifs identiques

- On note Q1 et Q3 le premier et troisième quartile respectivement
- Q2 = médiane


○ Ecart-interquartile (IQR)

$$\text{IQR} = Q3 - Q1$$

- L'IQR contient 50% des valeurs

○ Quantiles

Par ex les centiles sont chacune des 99 valeurs qui divisent les données triées en 100 parts égales



Utilisés dans les diagrammes Quantile-Quantile (ou Q-Q plot) pour évaluer la pertinence de l'ajustement d'une distribution donnée à un modèle théorique.

19

Paramètres de dispersion

○ Etendue

Différence entre le max et le min

○ Variance

Moyenne des carrés des écarts à la moyenne

Soit une population de N sujets pour lesquels les valeurs d'une variable X sont

$x_1, \dots, x_N$.

La variance de X est


$$\sigma_X^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

• On lit 'sigma carré'

20

3.2 Paramètres de dispersion

○ Variance



$$\sigma_B^2 > \sigma_A^2$$

i Plus la variable est dispersée, plus la variance est grande

Chap 1: Stat. Desc.

1. Terminologie
2. Comment décrire?
3. Paramètres statistiques
4. .../...

Somme des carrés des distances par rapport à la moyenne

$$\begin{aligned} & (x_1 - \bar{x})^2 \\ & + (x_2 - \bar{x})^2 \\ & + (x_3 - \bar{x})^2 \\ & + \dots \\ & + (x_N - \bar{x})^2 \\ & \hline & = \sum_{i=1}^N (x_i - \bar{x})^2 \end{aligned}$$

Moyenne des carrés des distances par rapport à la moyenne

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

21

Paramètres de dispersion

○ Ecart-type (*standard deviation*)

Racine carrée de la variance, que l'on note σ .

$$\sigma = \sqrt{\sigma^2}$$

○ Coefficient de variation

$$CV = \frac{\sigma}{\bar{x}}$$

i CV est sans dimension
On l'exprime généralement en %

○ Ecart moyen (ou déviation absolue moyenne de la moyenne)

$$E_m = \frac{1}{n} \sum_{i=1}^n |x_i - \bar{x}|$$

○ Déviation absolue moyenne d'une médiane

$$MAD = \frac{1}{n} \sum_{i=1}^n |x_i - \tilde{x}|$$

i Attention aux notations:
le barre sur x veut dire moyenne de x
le tilde sur x (la vague) veut dire médiane de x

22

Notion de moments


Un moment d'ordre r ($r \in \mathbb{N}$) d'une variable aléatoire X est défini, s'il existe par:

$$m_r \triangleq \mathbb{E}(X^r)$$

La **méthode des moments** permet d'estimer des paramètres de distributions à partir de mesures empiriques en égalisant certains moments théoriques avec leurs contreparties empiriques

Imaginons X une VA qui suit une **loi normale** (de paramètres (μ, σ)) que l'on cherche à estimer à partir de N observations X_i

PROPRIÉTÉS



23

Notion de moments

Moments théoriques d'une loi Normale

Ordre 1:

$$\mathbb{E}(X) \equiv m_1 = \mu$$

Ordre 2:

$$\mathbb{E}(X^2) \equiv m_2 = \mu^2 + \sigma^2$$

Moments empiriques des données

Ordre 1:

$$\hat{m}_1 = \frac{X_1 + X_2 + \dots + X_n}{n}$$

Ordre 2:

$$\hat{m}_2 = \frac{X_1^2 + X_2^2 + \dots + X_n^2}{n}$$

Si on égalise ces moments:

$$\hat{\mu} = \hat{m}_1 = m1$$

$$\hat{\sigma} = \sqrt{\hat{m}_2 - \hat{m}_1^2}$$

Code R

```
N <- 1e5
X <- rnorm(N, mean = 125, sd=12)
m1 <- sum(X)/N
m2 <- sum(X**2)/N

m1
## [1] 125.0444
mean(X)
## [1] 125.0444
m2-m1**2
## [1] 143.5496
var(X)
## [1] 143.551
```

On retrouve bien les valeurs de 125 et 12 pour les paramètres de la loi normale

24

Notion de moments

$$\hat{\sigma} = \hat{m}_2 - \hat{m}_1^2$$

$$\sigma_X^2 = \frac{1}{N} \left(\sum_{i=1}^N x_i^2 \right) - \bar{x}^2$$

Variance: La moyenne des carrés moins le carré de la moyenne

$$\sigma_X^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

Démo

$$\begin{aligned} \sum_{i=1}^N (x_i - \mu)^2 &= \sum_{i=1}^N (x_i^2 + \mu^2 - 2x_i\mu) = \sum_{i=1}^N x_i^2 + \sum_{i=1}^N \mu^2 - 2 \sum_{i=1}^N \mu x_i \\ &= \sum_{i=1}^N x_i^2 + N\mu^2 - 2\mu \cdot N\mu = \sum_{i=1}^N x_i^2 + N\mu^2 - 2N\mu^2 = \sum_{i=1}^N x_i^2 - N\mu^2 \end{aligned}$$

25

Notion de moments

Le moment centré d'ordre r ($r \in \mathbb{N}$) de X est défini, s'il existe par:

$$\mu_r \triangleq \mathbb{E}((X - \mathbb{E}(X))^r)$$


Le moment centré d'ordre 2 représente la variance

Moments remarquables

Le coefficient d'asymétrie (*Skewness*) est un moment centré réduit d'ordre trois

$$\gamma_1 \triangleq \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^3 \right]$$

pour une distribution symétrique $\gamma_1 = 0$,
puisque les moments d'ordre impairs sont alors nuls



Source: wikipedia

26

Notion de moments


Moments remarquables (suite)

Le **coefficient d'aplatissement** (*kurtosis*) est dérivé d'un moment centré réduit d'ordre quatre

$$\gamma_2 \triangleq \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right] - 3$$

On parle de distribution

- mésokurtique $\gamma_2 = 0$ (distribution Normale)
- leptokurtique $\gamma_2 > 0$
- platikurtique $\gamma_2 < 0$



Source: <https://stats.stackexchange.com>

27

Un petit résumé des moments...



Statistics 4 Data Science & ML
@stat4dsci

...


Attention Plz,
Statistical Moments: are a set of statistical
PARAMETERS to measure a DISTRIBUTION. Four
Moments in #Statistics

1. Mean
2. Standard Deviation
3. Skewness
4. Kurtosis

Generally, last two are discovered through VISUAL
DISPLAY

#DataScience #rstats #Machinelearning


First Moment:
mean - measure of location



Second Moment:
Standard deviation - measure of
spread



Third Moment:
skewness - measure of symmetry



Fourth Moment:
kurtosis - measure of peakedness




28

Analyse Descriptive – variable *age*

```
> library(summarytools)
> data1 <- read.csv("https://cutt.ly/AjWBjnr",h=T,dec='.', sep=";")
> descr(data1$age)
```

Descriptive Statistics
data1\$age
N: 200

	age
Mean	61.84
Std.Dev	9.72
Min	41.53
Q1	54.84
Median	60.62
Q3	68.05
Max	84.77
MAD	9.43
IQR	13.20
CV	0.16
Skewness	0.37
SE.Skewness	0.17
Kurtosis	-0.59
N.Valid	197.00
Pct.Valid	98.50



29


Analyse Descriptive – variable *deltaT.mois*

```
> descr(data1$deltaT.mois)
```

Descriptive Statistics
data1\$deltaT.mois
N: 200

	deltaT.mois
Mean	8.57
Std.Dev	7.51
Min	0.00
Q1	3.00
Median	7.00
Q3	13.00
Max	29.00
MAD	7.41
IQR	10.00
CV	0.88
Skewness	0.81
SE.Skewness	0.17
Kurtosis	-0.35
N.Valid	200.00
Pct.Valid	100.00

```
hist(data1$deltaT.mois, main="",
      xlab="recul, en mois",
      ylab="Effectifs",
      breaks=30,
      col=rgb(.6,.6,.6,.5))
box()
```



Quelques questions pour se tester...



Les Pressions Artérielles Diastoliques (PAD) de 12 patients sont les suivantes: 9,9,8,7,8,9,10,7,8,9,9,9 (en cm de Hg).

- Le mode de l'échantillon vaut 9 – vrai ou faux?
- La moyenne de l'échantillon vaut 9 – vrai ou faux?
- La médiane vaut ...
- La variance vaut ...
- Le premier quartile vaut ...

HELP!

```
import statistics as stat
PAD = [9,9,8,7,8,9,10,7,8,9,9,9]
stat.mode(PAD)
```



Les Pressions Artérielles Systoliques (PAS) de ces 12 mêmes patients valent: 13, 17, 11, 14, 18, 14, 14, 12, 14, 13, 12, 14 (en cm de Hg)

- La moyenne vaut ...
- La variance vaut ...
- Le coefficient d'asymétrie (skewness) est positif
- Le coefficient d'aplatissement (kurtosis) vaut ...
- La médiane est égale à une valeur de la série – vrai ou faux?

```
PAS <- c(13, 17, 11, 14, 18, 14, 14, 12, 14, 13, 12, 14)
mean(PAS)
```

HELP!

Amusez vous bien ! J

Éléments de correction...

Les Pressions Artérielles Systoliques (PAS) de ces 12 mêmes patients valent: 13, 17, 11, 14, 18, 14, 14, 12, 14, 13, 12, 14 (en cm de Hg)

Le coefficient d'aplatissement (kurtosis) vaut ... suspense... *Monsieur on y arrive pas* ☹

J'aime pas faire les calculs à la mains, mais puisque vous avez l'air d'y tenir....

Étape par étape:

La formule du cours $\gamma_2 \triangleq \mathbb{E} \left[\left(\frac{X - \mu}{\sigma} \right)^4 \right] - 3$

Ça m'aide moyen – il faut que je la réécrive sous forme d'un truc qui découle d'un moment empirique

$$\gamma_2 \triangleq -3 + \frac{1}{n} \sum_{i=1}^n \left[\left(\frac{x_i - \bar{x}}{\sigma} \right)^4 \right]$$

La feinte du -3 devant pour être sûr de ne pas le mettre dans la somme!!!!

Bon ben c'est presque fait... n=12, si i=1, $\left(\frac{x_i - \bar{x}}{\sigma} \right)^4 = \left(\frac{13 - \bar{x}}{\sigma} \right)^4, \dots$

Bon courage !!